Dysgu Peirianyddol

Cyflwyniad i algorithmau dysgu peirianyddol yn R a Python

Alun Owen

B.Sc. Traethawd Blwyddyn 3

Yr Ysgol Mathemateg Caerdydd

Diolchadau

Cynnwys

Rhestr Ddarluniau

Pennod 1

Cyflwyniad

1.1 Beth yw Dysgu Peirianyddol

1.1.1 Dysgu dan Oruchwyliaeth

1.1.2 Dysgu heb Oruchwyliaeth

1.1.3 Darllen Pellach

1.2 Pam

1.2.1 Be sydd yna yn barod?

1.2.2 Pam Python ag R?

1.2.3 Pam Cymraeg?

1.3 Strwythyr

Pennod 2

Clystyru k-cymedr

2.1 Cefndir

Mae clystyru k-cymedr yn ffordd o ddysgu heb oruchwyliaeth, mae'n cymryd data heb ei labelu ac yn eu sortio i mewn i k wahanol glwstwr yn yr obaith i ddarganfod rhyw strwythur doedden ddim yn gwybod yn gynharach.

I roi enghraifft gwelwch Ddarlun 2.1. Mae'r gwerthoedd ar echelin x yn cynrychioli uchder rhyw berson a'r llall yn cynrychioli pwysau'r person. Fel gwelwn yn y llun ar y chwith gallwn weld tri grŵp naturiol wedi'i ffurfio. Rydym nawr eisiau eu grwpio yn ffurf Fathemategol. Mae clystyru k-cymedr yn medru dosrannu'r tri grŵp fel gwelwn ar ochr dde'r darlun.

2.2 Sut mae Clystyru K-cymedr yn gweithio?

2.2.1 Y Dull

Mae clystyru k-cymedr yn syml, mae ond yn dilyn pedwar cam [1]. I wneud yn siŵr fod yn ei ffurf fwyaf cyntefig, fyddan yn defnyddio mesur pellter Ewclidaidd. Yn ogystal mae rhaid dewis k cyn cychwyn y

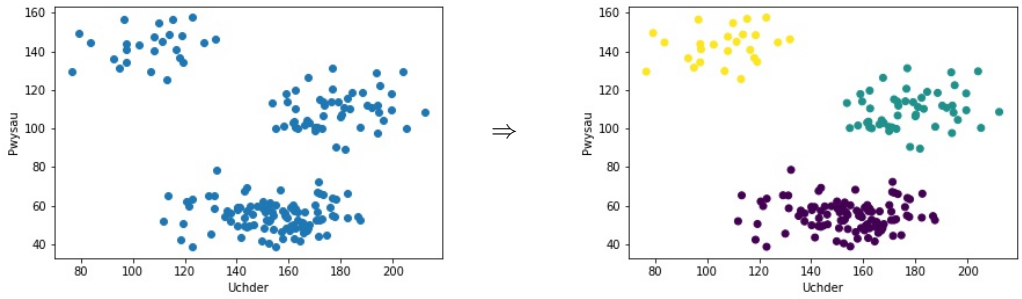

Darlun 2.1: Cyn ac ar ôl clystyru k-cymedr.

proses. Mae'n bosib optimeiddio'r dewis o k, a gwnawn drafod hyn hwyrach ymlaen. Dyma bedwar cam yr algorithm a sut maent yn edrych pan fyddwn ni'n defnyddio'r algorithm ar y data y gwelwn yn 2.1:

1. Aseinio pob elfen i un o'r k clystyrau ar hap.

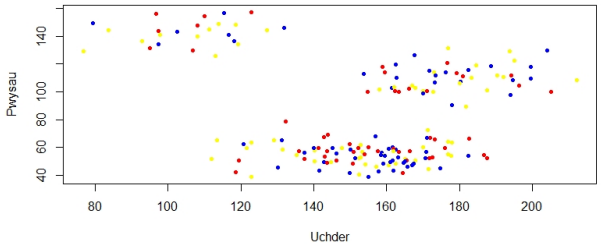

Darlun 2.2: Enghraifft o set cychwynol ar gyfer clystyru.

2. Cyfrifo canolbwynt (hynny yw craidd) pob clwstwr.

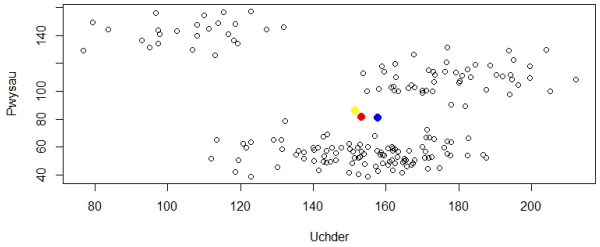

3. Ail-aseinio pob elfen unwaith eto i'r clwstwr gyda craidd agosaf.

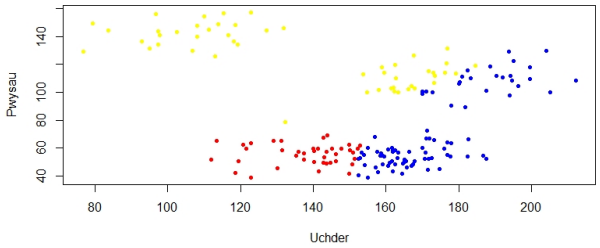

4. Ailadrodd camau dau a tri tan fod y creiddiau ddim yn symud rhagor.

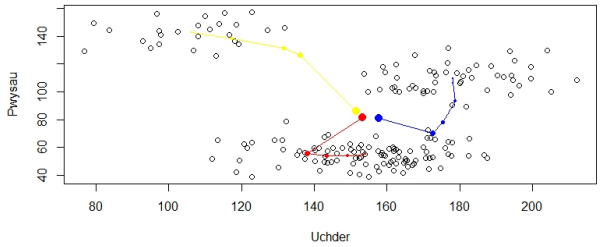

2.2.2 Yr Algorithm

Diffiniwn bob clwstwr rydym yn ceisio darganfod fel C_i lle bydd $i \in \{1, 2, \ldots, k\}$, mae gennym hefyd n pwyntiau data $x_1, x_2, \ldots, x_n$. Gadewch i $\mathbf{c}_i$ bod yn bwynt sy'n graidd i clwstwr C_i. Ar gyfer y cam cyntaf angen aseinio pob $\mathbf{x}_j$ i ryw glwstwr C_i ar hap. Yna gan ein bod yn datgelu ein bod yn delio gyda phlân Ewclidaidd, mi fyddem yn darganfod craidd pob clwstwr gan y fformiwla ganlynol:

$$\mathbf{c}_i = \frac{1}{|S_i|} \sum_{\mathbf{x}_j \in S_i} \mathbf{x}_j \tag{2.1}$$

Yn y fformiwla uchod, gwelwn fod fectorau yn cael eu symio. Fyddem yn gwneud hyn gan symio dros elfennau. [1]

lle diffiniwn S_i fel y set o bwyntiau data sydd wedi'i aseinio i glwstwr C_i.

Nawr mae gan bob clwstwr craidd newydd, fedrwn aseinio pob pwynt data i'r craidd agosaf. Caiff hyn ei gwneud gan fynd drwy bob pwynt data a chyfrifo'r pellter Ewclidaidd [2] i bob canolbwynt. Yna fydd y pwynt priodol yn cael ei labelu gyda'r clwstwr sydd a'r pellter lleiaf o'i graidd i'r pwynt data. Hynny yw

$$\arg\min_{\mathbf{c}_i} ||\mathbf{c}_i, \mathbf{x}_j||^2 \tag{2.2}$$

Unwaith mae'r proses wedi'i chychwyn, angen ailadrodd y darn o ddarganfod y creiddiau newydd ac ail labelu'r pwyntiau data tan fod y creiddiau ddim yn symyd rhagor.

2.2.3 Sut i ddarganfod y k orau?

Mae yna wahanol ffurf i ddarganfod k, edrychwn ar ddau wahanol ffordd o wneud hyn.

Dull Penelin

Mae'r dull penelin yn cymharu'r cyfanswm o swm sgwariau o fewn y clystyrau. Unwaith gennym y cyfanswm o swm sgwariau o fewn clystyrau i bob k rydym eisiau cymharu, fyddem yn creu plot o bob k yn erbyn y

[1] $(x_1, x_2, \ldots, x_n) + (y_1, y_2, \ldots, y_n) = (x_1 + y_1, x_2 + y_2, \ldots, x_n + y_n)$
[2] $||\mathbf{p} - \mathbf{q}|| = \sqrt{(p_1 - q_1)^2 + (p_2 - q_2)^2 + \cdots + (p_n - q_n)^2}$

cyfanswm o swm sgwariau o fewn y clystyrau ar gyfer y k hynny. Fydd swm sgwariau ar gyfer clwstwr C_i yn cael ei darganfod gan symio y pellter rhwng y craidd $\mathbf{c}_i$ a phob $\mathbf{x}_j$ yn ei tro ag yno ei sgwario fel welwn yn y fformiwla:

$$SS_i = \sum_{j=1}^{n} (\mathbf{x}_j - \mathbf{c}_i)^2$$

Unwaith mae gennym y graff, allwn ei ddadansoddi.

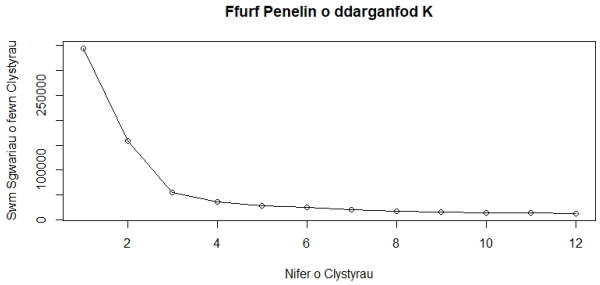

Darlun 2.3: Enghraifft o blot o k yn erbyn y cyfanswm swm o sgwariau

Yn y graff yn Narlun 2.3, gwelwn fod swm sgwariau yn fawr yn cychwyn gyda k=1 sydd yn gwneud synnwyr. O'r pwynt yma wedyn fydd yna newid mawr yn y swm sgwariau. Unwaith mae'r newid mawr hwn yn dod i ben fydd gennym ongl yn cael ei greu lle bydd newid k dim ond yn creu newid bach. Y pwynt yma fydd yr optimwm ar gyfer nifer k o glystyrau. Fel gwelwn yn glir yn ein henghraifft ni, mae'n glir fod K=3 yw dewis orau ar K.

Dendrogram

Mae dendrogram yn ffordd wahanol iawn i canfod y nifer orau k o glystyrau. Mae'n defnyddio darn o glystyru hierarchaidd i greu diagram canghennog. Mae'r echelin llorweddol yn dangos pob gwrthrych yn ein set o ddata. Mae'r echelin fertigol yn dangos mesur o annhebygrwydd. Mae Darlun 2.4 yn dangos dendogram ar gyfer yr un data.

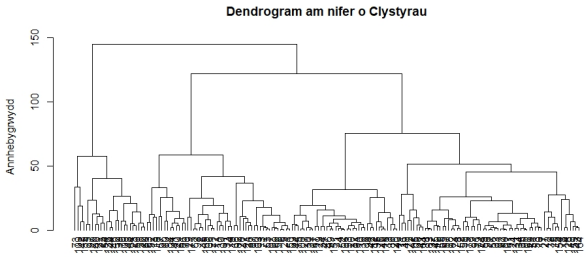

Darlun 2.4: Enghraifft o dendogram

I ddadansoddi'r dendrogram mi fyddwn edrych yn bennaf ar yr echelin fertigol. Edrychwn allan am yr annhebygrwydd fwyaf rhwng cyflwyniad o gangen arall yn y goeden. Welwn ni hyn yn ein henghraifft ni ar ôl i'r drydydd clwstwr cael ei gyflwyno yn dendrogram. Mae hyn yn datganu'r un peth a'r dull penelin.

2.3 Tiwtorial yn R

Mi fyddwn yn edrych ar ddata o uchder a phwysau 175 wahanol berson. Mi allwch chi lawrlwytho y data yma o fan hyn.

Yno fydd angen lawrlwytho a gosod y pecynnau `graphics`, `stats` ag `datasets` ar eich cyfrifiadur. Ffordd hawdd i wirio hyn fydd i ddefnyddio'r côd canlynol:

```
install.packages("graphics")
install.packages("stats")
install.packages("datasets")
library(graphics)
library(stats)
library(datasets)
```

Mae'r darn gyntaf o'r côd uchod yn gosod/diweddaru'r pecynnau angenrheidiol. Mae'r ail ddarn yn llwytho'r pecynnau i ein sesiwn ni.

Nawr mi wnawn lwytho'r data.

```
uchderpwysau <- read.csv("C:/Users/User/Desktop/Dysgu_Peirianyddol/heightvsweight.csv")
View(uchderpwysau)
```

Mae'r string sydd mewnbwn y ffwythiant `read.csv` yn cyfeirio at y lleoliad ar ein cyfrifiadur lle gallwn ganfod y ffeil csv priodol. Rhaid gwneud yn siŵr eich bod yn defnyddio'r lleoliad cywir i'r lleoliad o'ch ffeil chi. Ar ôl rhedeg y côd ddylai eich data edrych yn debyg i'r canlynol:

	Uchder	Pwysau
1	163.22687	100.09760
2	183.18087	110.18107
3	172.69407	99.79701
4	165.07549	51.66760
5	147.74605	59.79469
6	161.45039	103.04177
7	162.41267	58.50832
8	146.28025	50.36660
9	154.03614	47.93155
10	152.20904	59.79795

Gan fod y data hefo enwau ar gyfer y colofnau, gallwn atodi'r data i lwybr chwilio R. Bydd hyn yn gadael i ni gyfeirio at enwau colofnau'r data yn ein côd fydd yn gwneud yn lawer mwy symlach i ddeall.

```
attach(uchderpwysau)
```

I wneud fwy o synnwyr o'r data, mi wnawn blotio'r data.

```
plot(Uchder, Pwysau, pch = 21)
```

Sy'n rhoi:

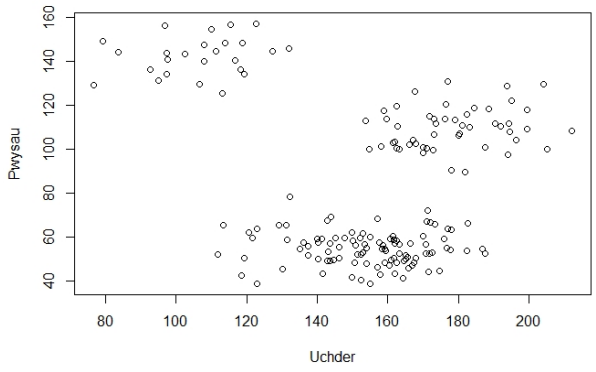

Gwelwn fod yna 3 clwstwr clir.

Rŵan rydym yn gallu tybio fod y data yn gallu cael i rannu i dri chlwstwr gwahanol, mi wnawn ddefnyddio'r algorithm dysgu peirianyddol i'w ddehongli. Rhedwn y canlynol i redeg clystyru k-cymedr yn R. Rydym yn

defnyddio'r ymresymiad `nstart` i ddewis faint o setiau ar hap o ddata wedi'i labelu wnawn gymered. Welwn enghraifft o'r set ar hap hyn yn Darlun 1. Rydym yn neud hyn i wneud yn fwy debygol i ni ddarganfod yr uchafbwynt eang, mae hyn oherwydd mae yna gymaint o uchafbwyntiau lleol.

```
kcymedr <- kmeans(uchderpwysau,3, nstart = 50)
```

Allwn nawr adio colofn newydd i'r data sef y clystyrau newydd mae'r algorithm wedi'i darganfod.

```
uchderpwysau$Clwstwr3 <- kcymedr$cluster
```

Gallwn weld y newid hwn gan ddefnyddio'r un côd a ddefnyddion yn gynharach.

```
View(uchderpwysau)
```

	Uchder	Pwysau	Clwstwr3
1	163.22687	100.09760	1
2	183.18087	110.18107	1
3	172.69407	99.79701	1
4	165.07549	51.66760	2
5	147.74605	59.79469	2
6	161.45039	103.04177	1
7	162.41267	58.50832	2
8	146.28025	50.36660	2
9	154.03614	47.93155	2
10	152.20904	59.79795	2

Mae'n bosib fydd yr algorithm wedi labeli'r clystyrau gwahanol gyda rhifau gwahanol i'r hyn a welwch fan hyn, ddylai'r clystyrau ei hun fod yn hafal. Mae hyn oherwydd y setiau ar hap cychwynnol mae'r algorithm yn ei gymered i gychwyn.

Rhedwn y côd canlynol liwio'r clystyrau newydd ar graff.

```
plot(Uchder, Pwysau, pch = 21, bg=c("red","green","blue")[unclass(kcymedr$cluster)])
```

Sy'n rhoi:

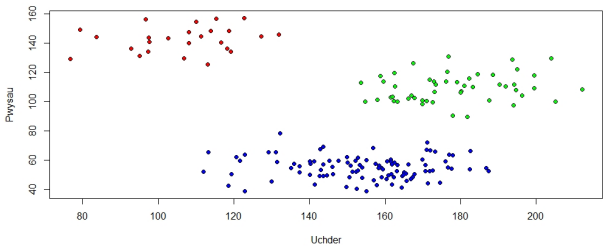

I gymharu, nawr mi nawn rhedeg yr algorithm ar gyfer 6 clwstwr i weld y clystyrau pan fydd $k = 6$.

```
kcymedr <- kmeans(uchderpwysau,6, nstart = 50)
uchderpwysau$Clwstwr6 <- kcymedr$cluster
View(uchderpwysau)
```

	Uchder	Pwysau	Clwstwr3	Clwstwr6
1	163.22687	100.09760	1	1
2	183.18087	110.18107	1	6
3	172.69407	99.79701	1	1
4	165.07549	51.66760	2	4
5	147.74605	59.79469	2	2
6	161.45039	103.04177	1	1
7	162.41267	58.50832	2	4
8	146.28025	50.36660	2	2
9	154.03614	47.93155	2	2
10	152.20904	59.79795	2	2

Gwelwn fod y labeli newydd wedi cael ei ychwanegu i'n tabl. Yna gan blotio graff arall, fedrem weld y 6 clwstwr yn gliriach.

```
lliwiau <- c("red","green","blue", "yellow", "black", "white")
plot(Uchder, Pwysau, pch = 21, bg=lliwiau[unclass(kcymedr$cluster)])
```

Sy'n rhoi:

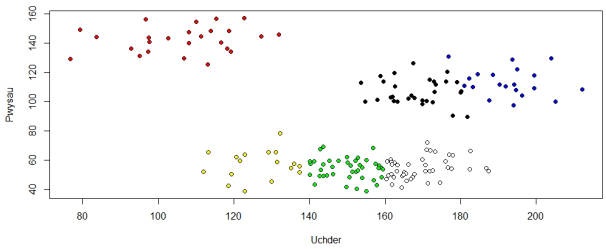

2.4 Tiwtorial yn python

Yn y tiwtorial hwn mi wnawn edrych ar yr un data a welom yn y tiwtorial diwethaf. I gychwyn bydd rhaid llwytho'r pecynnau `pandas`, `matplotlib.pyplot` ag `sklearn.cluster` drwy redeg y côd canlynol:

```
import pandas as pd
import matplotlib.pyplot as plt
import sklearn.cluster
```

Y rŵan mi wnawn lwytho'r data i mewn i'n gwaith gan redeg y côd:

```
data = pd.read_csv('heightvsweight.csv')
```

Mae'r string sydd mewnbwn y ffwythiant `pd.read_csv` yn cyfeirio at y lleoliad ar ein cyfrifiadur lle gallwn ganfod y ffeil csv priodol. Rhaid gwneud yn siŵr eich bod yn defnyddio'r lleoliad cywir i'r lleoliad o'ch ffeil chi. Unwaith fydd wedi cael ei llwytho, allwn ni gweld yn fras y data gennym ni.

```
data.head()
```

	Uchder	Pwysau
0	163.226866	100.097603
1	183.180871	110.181072
2	172.694074	99.797013
3	165.075492	51.667604
4	147.746048	59.794691

I weld y data mewn ffordd fwy gweledol, wnawn blotio graff gwasgariad o'r data.

```
plt.scatter(data['Uchder'], data['Pwysau']);
plt.xlabel('Uchder')
plt.ylabel('Pwysau')
plt.show()
```

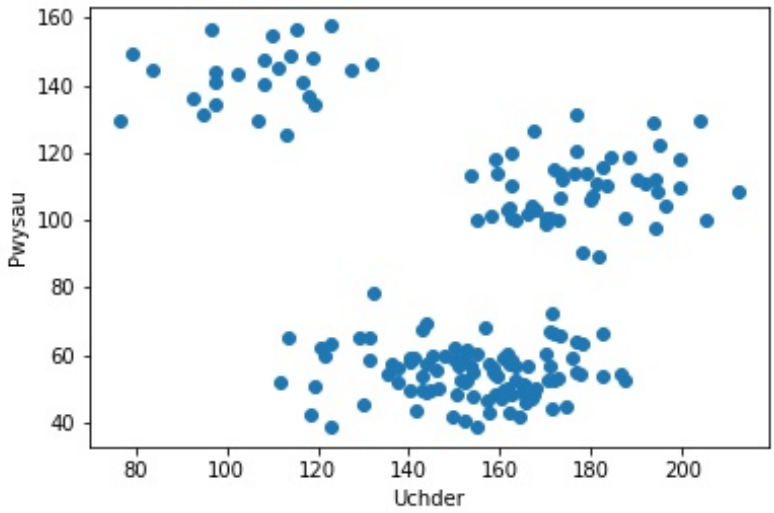

Darlun 2.5: Enghraifft o ddata da i cael ei clystyru.

Fel gwelwn, mae'r data yn edrych fel ei fod mewn tri chlwstwr. Felly wnawn ddefnyddio'r ffurf algorithm dysgu peirianyddol i'w labelu.

```
kmeans = sklearn.cluster.KMeans(n_clusters=3).fit(data)
data['Cluster (k=3)'] = kmeans.predict(data)
```

Gallwn weld y newid hwn gan ddefnyddio'r un côd a ddefnyddion yn gynharach.

```
data.head()
```

	Uchder	Pwysau	Cluster (k=3)
0	163.226866	100.097603	1
1	183.180871	110.181072	1
2	172.694074	99.797013	1
3	165.075492	51.667604	0
4	147.746048	59.794691	0

Fel y gwelwyd, mae'r data wedi'i rhoi i mewn i dri chlwstwr ac wedi'i labelu gyda rhif y clwstwr. Gan fod pob pwynt yn y data nawr gyda label, allwn ni creu'r plot eto ond gyda bob clwstwr yn lliw gwahanol.

```
plt.scatter(data['Uchder'], data['Pwysau'], c=data['Cluster (k=3)']);
plt.xlabel('Uchder')
plt.ylabel('Pwysau')
plt.show()
```

Sy'n rhoi:

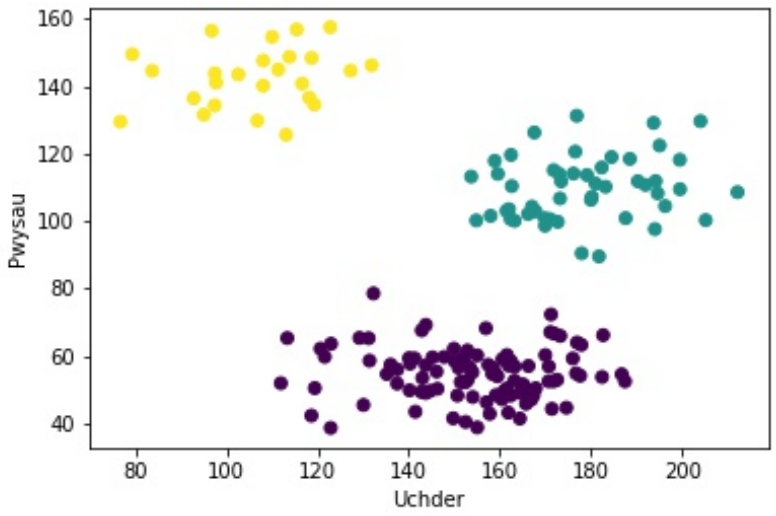

Darlun 2.6: Sut ddylsa eich graff edrych gyda 3 clystwr.

Fel y gwelwn, gweithiodd yr algorithm yn wych. Wnawn nawr trio clystyru k-cymedr gyda k yn hafal i 6.

```
kmeans = sklearn.cluster.KMeans(n_clusters=6).fit(data)
data['Cluster (k=6)'] = kmeans.predict(data)
```

Sy'n rhoi:

```
data.head()
```

	Uchder	Pwysau	Cluster (k=3)	Cluster (k=6)
0	163.226866	100.097603	1	4
1	183.180871	110.181072	1	2
2	172.694074	99.797013	1	4
3	165.075492	51.667604	0	0
4	147.746048	59.794691	0	3

Gallwn hefyd gweld canlyniad rhoi'r data i mewn i 6 clwstwr gwahanol:

```
plt.scatter(data['Uchder'], data['Pwysau'], c=data['Cluster (k=6)']);
plt.xlabel('Uchder')
plt.ylabel('Pwysau')
plt.show()
```

Sy'n rhoi:

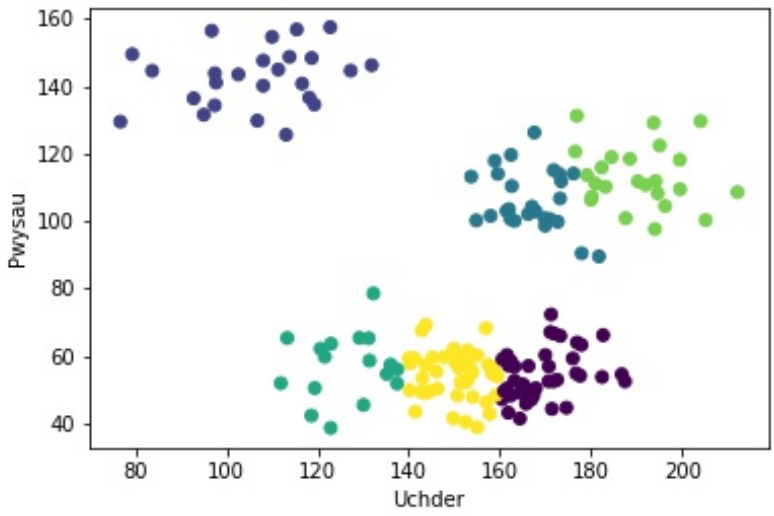

Darlun 2.7: Sut ddylsa eich graff edrych gyda 6 clystwr.

Dyma sut dylaf eich data edrych fel ar ôl a phrosesu drwy glystyru 6-cymedr.

Pennod 3

Atchweliad logistaidd

3.1 Cefndir

Defnyddiwn atchweliad logistaidd i fodelu'r tebygolrwydd o ddosbarthu gwrthrych i mewn i setiau deuaidd. Mae'n ddull o ddysgu dan oruchwyliaeth sy'n cael ei ddefnyddio yn aml yn academïau a diwydiannau. Gall y atchweliad cael ei ddefnyddio i weld os mae rhywun yn curo/colli, sâl/iachus neu basio/methu mewn rhyw sefyllfa benodol. Gall y syniad yma cael ei ymestyn, gall wahanol atchweliadau logistaidd cael ei rhoi yn baralel i geisio rhoi'r tebygolrwydd o liw llygaid rhyw berson er enghraifft. Mewn termau mwy cyffredinol, gall ymestyn atchweliadau logistaidd i weithio ar setiau o labeli di-deuaidd. O hyn ymlaen fyddem yn edrych ar un atchweliad ar un waith, felly fydd y setiau o labeli yn ddeuaidd.

Mae'n hawdd delweddu sut fydd atchweliad logistaidd gydag un newidyn annibynnol. Gwelwn fod y model yn edrych fel y graff yn ddarlun **??** pan hyn yw'r sefyllfa.

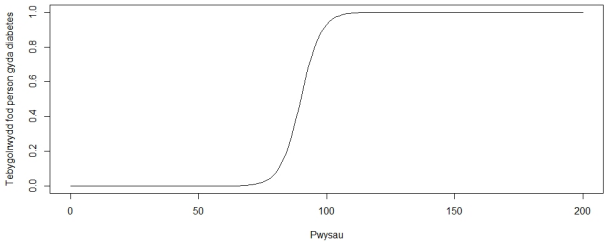

Darlun 3.1: Enghraiff o atchweliad logistaidd.

Gwelwn yn y graff nesaf fod y plot yn dangos ein data yn wych.

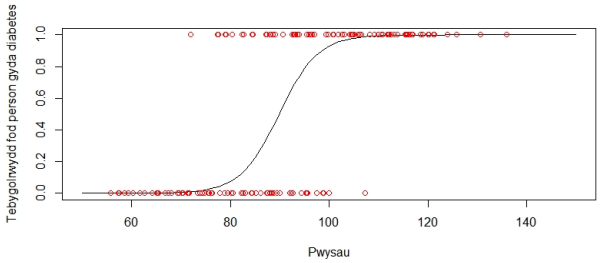

Darlun 3.2: Enghraiff o atchweliad logistaidd gyda labelau.

Mae hyn hyd yn oed fwy cywir pan fyddem yn cymharu atchweliad logistaidd i atchweliad llinol.

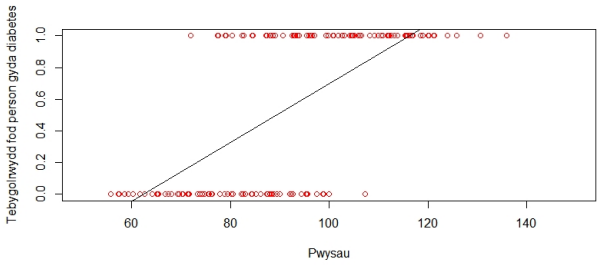

Darlun 3.3: Enghraiff o atchweliad llinol i ein data.

3.2 Sut mae Atchweliad logistaidd yn gweithio?

Wnawn ddiffinio'r fector sy'n cynnwys gwybodaeth am berson j ($j \in 1, \ldots, n$) gyda $\mathbf{x}_j$ sydd hefo dimensiwn o m (hynny yw bod yna m priodoleddau). Yn ogystal, wnawn ddiffinio y_j fel label deuaidd i berson j. Yna gydag ein data fydd rhaid i ni wahanu'r data i mewn i ddata ymarfer ac ddata profi. Fydd hyn yn cael ei wneud ar hap. Felly fydd gennym:

Data ymarfer - $\mathbf{x}_j$ a y_j ar gyfer $j \in \{1, \ldots, k\}$ lle mae $k < n$

Data profi - $\mathbf{x}_j$ a y_j ar gyfer $j \in \{k+1, \ldots, n\}$

Nawr wnawn edrych ar y ffwythiant logistaidd, lle mae $z \in (-\infty, \infty)$:

$$f(z) = \frac{1}{1 + e^{-z}}$$

Mae'r model logistaidd yn cymryd y ffurf logit, mae hyn yn cael ei ddangos yn hafaliad 3.1.

$$z = \alpha + \beta_1 X_1 + \cdots + \beta_m X_m \tag{3.1}$$

Felly mae'r hafaliad yn dangos y model yn hafaliad 3.2.

$$P(\mathbf{x}) = P(y = 1|x_1 \dots x_k) = \frac{1}{1 + e^{-(\alpha + \sum_{i=1}^{m} \beta_i x_i)}} \tag{3.2}$$

3.2.1 Yr Algorithm

Fydd α a β y paramedrau fyddem yn trio amcangyfrif. I amcangyfrif hyn wnawn ddefnyddio'r dull amcangyfrif tebygoliaeth fwyaf. Cymerwn $\hat{\theta}$ i fod y fector o baramedrau fyddem yn amcangyfrif. Yna mae gennym y amcangyfrif tebygoliaeth ganlynol a fyddem yn trio cael y gwerth agosaf i 1:

$$L(\hat{\mathbf{z}}) = \prod_{s \in y_i = 1} p(x_i) \prod_{s \in y_i = 0} (1 - p(x_i))$$

Sydd yn gallu cael ei symleiddio i:

$$L(\hat{\mathbf{z}}) = \prod_{i=1}^{k} p(x_i)^{y_i} (1 - p(x_i))^{1 - y_i}$$

Nawr fyddem yn cymryd y log o'r amcangyfrif tebygoliaeth.

$$\log L(\hat{\mathbf{z}}) = \sum_{i=1}^{n} y_i log(p(x_i)) + (1 - y_i) log(1 - p(x_i))$$

Sydd yn symleiddio i:

$$\log L(\hat{\mathbf{z}}) = \sum_{i=1}^{n} y_i log(\frac{1}{1 + e^{-\hat{\mathbf{z}}\mathbf{x}}}) + (1 - y_i) log(\frac{e^{-\hat{\mathbf{z}}\mathbf{x}}}{1 + e^{-\hat{\mathbf{z}}}})$$

ac yna..

$$\log L(\hat{\mathbf{z}}) = \sum_{i=1}^{n} y_i \hat{\mathbf{z}} x_i - \log(1 + e^{\hat{\mathbf{z}} x_i})$$

Yna mae gennym y log o'r amcangyfrif tebygoliaeth. Rydym eisiau darganfod y gwerth o z lle mae'r log o'r amcangyfrif tebygoliaeth ar ei fwyaf.

$$\hat{\mathbf{z}} = \arg\max_{\mathbf{z}} \log L(\mathbf{z})$$

Does yna ddim ffordd bendant o ddarganfod y rhif/rhifau sy'n bodloni'r hafaliad uchod, fydd angen defnyddio algorithmau fel swm lleiaf sgwariau wedi eu hail bwyso drwy iteriadau neu ddisgyniad fwyaf fel gwelwn yn y algorithmau yn R ac python yn y drefn honno.

(ANGEN ADIO DARN AM Y DAU ALGORITHM)

Unwaith mae gennym amcangyfrif o'r paramedrau, mae gennym y model logistaidd ac felly dydi o ddim ond yn gwestiwn o roi ein data profi x_j i mewn i'r model. Fel allbwn cawn rif rhwng 0 ac 1, yna wnawn talgrynnu'r allbwn. Wedyn mae gennym ein rhagfynegiad am label pob person, yna gallwn ddarganfod cyfradd llwyddiant ein model gan:

$$1 - \sum_{j=k+1}^{n} \frac{(P(\mathbf{x}_j) - y_j)^2}{n-k}$$

3.3 Tiwtorial yn R

Yn yr enghraifft hon, fyddwn yn edrych ar ddata ar 1000 o bobol, fydd y data yn cynnwys gwybodaeth ar uchder, pwysau, maint gwasg, oed, rhyw ag oes gan y person diabetes. Mae'n bosib lawrlwytho'r data oddi yma: (INSERT LINK).

Ar gyfer gwneud atchweliad logistaidd, rydym dim ond angen y pecyn `stats` a wnawn ei lawrlwytho a'i gosod gan redeg y canlynol:

```
install.packages("stats")
library(stats)
```

Yna fydd rhaid i ni gael y data i mewn i ein consol gan lwytho'r data i mewn a'i arbed fel newidyn. Fydd rhaid neud yn siŵr fod y ffwythiant `read.csv` yn cael ei chyfeirio tuag at y lleoliad cywir o le mae eich data chi wedi'i gadw.

```
data <- read.csv("C:/Users/User/Desktop/Dysgu_Peirianyddol/data_logistic.csv")
```

Unwaith ei fod ar ein consol, mae'n bosib gweld y data:

```
View(data)
```

	Uchder	Pwysau	MaintGwasg	Oed	Rhyw	Diabetes
1	170.7197	87.70995	40.21594	57	Gwryw	0
2	159.2646	91.67977	39.95974	62	Gwryw	1
3	154.9078	98.35737	34.58633	29	Gwryw	0
4	168.5475	93.48007	41.47911	54	Benyw	1
5	175.8423	79.65120	34.53736	23	Benyw	0
6	169.7488	91.99920	39.35820	44	Benyw	1
7	143.8323	102.34901	42.13036	59	Benyw	1
8	157.2371	88.39940	41.19644	24	Benyw	1
9	197.6471	102.07920	36.38416	60	Gwryw	0
10	156.2165	91.67034	37.50940	27	Gwryw	0

Nawr wnawn rannu'r data felly fod data ymarfer yn cael 70% o'r data ac mae'r data profi yn cael 30% o'r data. Fyddwn yn rhannu'r data ar hap.

```
rhifau <- c(1:1000)
rhifauymarfer <- sample(x = rhifau, size = 700, replace = FALSE)
rhifauprofi <- setdiff(rhifau, rhifauymarfer)
```

Mae'r côd uchod yn rhannu'r setiau gan ddefnyddio eu cofnod o fynediad (rhif y rhes) yn y data ac yno mae'r côd isod yn rhannu'r fectorau i mewn i setiau arwahan.

```
ymarfer <- data[rhifauymarfer,]
profi <- data[rhifauprofi,]
```

Nawr rydym yn barod i greu'r model logistaidd. I greu'r model fyddem yn rhedeg y côd gan ddefnyddio y ffwythiant `glm`, sydd yn fyr am "Generalized Linear Models" sydd yn golygu gall y ffwythiant cael ei ddefnyddio am lawer fwy o atchweliadau na logistaidd yn unig. Oherwydd hyn mae'n bwysig i gofio rhoi'r opsiwn o `family` yn hafal i binomial. I ddilyn strwythur o'r algorithm, mae'n bwysig neud yn siŵr fod rydym yn creu'r model o'r data ymarfer yn unig.

```
atchweliad <- glm(Diabetes ~ Uchder + Pwysau + Oed + Rhyw + MaintGwasg,
                  family = binomial,
                  data = ymarfer)
```

Unwaith mae'r model wedi'i greu, gallwn weld eu paramedrau sydd wedi cael ei amcangyfrif:

```
atchweliad$coefficients
```

```
 (Intercept)       Uchder       Pwysau          Oed
22.858432583 -0.254347133  0.215272873  0.057360113
   RhywGwryw   MaintGwasg
-8.074052403 -0.003206262
```

Felly mae'r model sydd gennym yn edrych fel i dri lle degol:

$$P(\mathbf{x}) = \frac{1}{1 + e^{-22.858 + 0.254 x_{Uchder} - 0.215 x_{Pwysau} - 0.057 x_{Oed} + 8.074 x_{Rhyw} + 0.003 x_{MaintGwasg}}}$$

Gan fod ein model wedi'i chwblhau, gallwn weld sut mae'n perfformio yn penderfynu os oes gan bobl y set profi diabetes ta ddim. Geith hyn ei wneud yn defnyddio'r ffwythiant `predict` a dewis yr opsiwn `type` fel "response" i gael allbwn o debygolrwydd. Heb wneud hyn, fydd yr allbwn yn defnyddio'r ffurf logit fel gwelwn yn hafaliad 3.1

```
canlyniad <- round(predict(object = atchweliad, newdata = profi, type = "response"), digits = 0)
canlyniad <- unname(canlyniad)
```

Fyddem yn ogystal yn talgrynnu'r tebygolrwydd o bob person i cael dewis ar os gennym ddiabetes ta ddim. Wedyn fyddem yn tynnu i ffwrdd y rhifau o'r rhesi ar y fector o labeli. Nawr gennym y rhagfynegiad a'r canlyniadau gwreiddiol, gallwn gyfrifo'r canran o'r ddau set sy'n debyg. Gallwn gyfrifo yn y ffurf ganlynol gan fod ein setiau yn ddeuaidd.

```
1-(sum((test[,6]-unname(canlyniad))**2)/length(test[,6]))

0.8833333
```

Fel y gwelwn, mae ein model gydag effeithiolrwydd o 88% ar gyfer y data sydd gennym. Gallwn ni defnyddio y model rydym wedi creu i benderfynu ar os gan berson newydd ar hap diabetes neu ddim. Gwelwn hyn gan gyflwyno dyn gydag uchder o 160, pwysau 92, maint gwasg o 34 ag ugain oed yn y côd isod:

```
unname(round(predict(object = atchweliad,
                     newdata = data.frame(Uchder = 160,
                                          Pwysau = 92,
                                          MaintGwasg = 34,
                                          Oed = 20,
                                          Rhyw = "Gwryw"),
                     type = "response"),
             digits = 0))

0
```

Am y person yma gwelwn fod y model wedi rhagfynegu fod does ganddo ddim diabetes. Os wnawn ystyried person gyda'r un nodweddion ond yn fenyw:

```
unname(round(predict(object = atchweliad,
                     newdata = data.frame(Uchder = 160,
                                          Pwysau = 92,
                                          MaintGwasg = 34,
                                          Oed = 20,
                                          Rhyw = "Benyw"),
                     type = "response"),
             digits = 0))

1
```

Gwelwn fod gyda diabetes.

3.4 Tiwtorial yn Python

Ar gyfer cynhyrchu atchweliad logistaidd yn python mae rhaid i ni ddefnyddio'r pecynnau `sklearn` a `pandas`. Wnawn lwytho'r pecynnau gan redeg y côd yma.

```
from sklearn.linear_model import LogisticRegression
import pandas as pd
```

Nawr mae angen llwytho'r data, wnawn ddefnyddio'r un data wnaethom ddefnyddio i'r tiwtorial yn R. Cewch ei lawrlwytho o .... Mae'n cynnwys 1000 cofnod o fynegiadau ar fesuriadau pobl yn cynnwys uchder, pwysau, maintgwasg, oed, rhyw ag label yn dangos os gan y person diabetes neu ddim.

```
data = pd.read_csv('data_logistic.csv')
```

Gallwn gweld yr data gan rhedeg:

```
data.head()
```

	Uchder	Pwysau	MaintGwasg	Oed	Rhyw	Diabetes
0	170.719652	87.709946	40.215944	57	Gwryw	0
1	159.264575	91.679774	39.959742	62	Gwryw	1
2	154.907775	98.357373	34.586330	29	Gwryw	0
3	168.547460	93.480071	41.479106	54	Benyw	1
4	175.842260	79.651198	34.537361	23	Benyw	0

Gan fod ein data gyda rhyw wedi cael ei diffinio gyda'r geiriau "Gwryw" a "Benyw", mae python yn cael trafferth yn delio gyda nhw. Felly nawn trawsnewid nhw i newidyn deuaidd (set o 1 a 0).

```
data['Rhyw'] = data['Rhyw'].apply(lambda x: int(x =='Gwryw'))
```

Nawr fydd rhaid i ni rannu'r data i ddata ymarfer ag data profi.

```
ymarfer = data.sample(frac = 0.7)
profi = data.drop(ymarfer.index)
```

Mae'r wybodaeth rydym angen i greu model logistaidd angen fod yn fatrics yn python, felly:

```
X = ymarfer[['Uchder', 'Pwysau', 'MaintGwasg', 'Oed', 'Rhyw']].as_matrix()
y = ymarfer['Diabetes'].as_matrix()
X_profi = profi[['Uchder', 'Pwysau', 'MaintGwasg', 'Oed', 'Rhyw']].as_matrix()
y_profi = profi['Diabetes'].as_matrix()
```

I redeg yr atchweliad logistaidd wnawn ddefnyddio'r ffwythiant yn `sklearn`. Wnawn wneud gan redeg y côd canlynol:

```
clf = LogisticRegression(random_state=0).fit(X, y)
```

Gallwn edrych ar y rhyngdoriad gan

```
clf.intercept_
```

```
array([ 1.70933553])
```

ac yna y paramedrau eraill:

```
clf.coef_
```

```
array([[-0.12384414,  0.14710498,  0.12995053,  0.04682347, -4.80795833]])
```

Felly dyma yw ein model i dri lle degol:

$$P(\mathbf{x}) = \frac{1}{1 + e^{-1.709 + 0.124 x_{Uchder} + 0.147 x_{Pwysau} - 0.047 x_{Oed} + 4.808 x_{Rhyw} - 0.130 x_{MaintGwasg}}}$$

Nawr gallwn ni cyfrifo'r gyfradd llwyddiant o ein model ar y data profi. Gallwn ei chyfrifo yn y ffordd ganlynol oherwydd ein bod yn delio gyda data deuaidd.

```
1-(sum((clf.predict(X_profi)-y_profi)**2)/len(y_profi))
```

```
0.91666666666666663
```

Felly mae ein model logistaidd yn python yn rhoi cyfradd llwyddiant o tua 92%. Gallwn nawr ei ddefnyddio ar gyfer rhyw berson tŷ allan i ein data. Os oes gennym wryw gyda thaldra o 171, pwysau o 130 a maint gwasg ag oed o 40; gallwn ragfynegi os oes gan y person diabetes ta ddim.

```
clf.predict([[171, 130, 40, 40,1]])
```

```
array([1], dtype=int64)
```

Gwelwn fod gan y person hwn diabetes yn ôl y model logistaidd rydym wedi'i greu. Nawr nawn drio gyda person tebyg ond gyda phwysau o 90 nlle.

```
clf.predict([[171, 90, 40, 40,1]])
```

```
array([0], dtype=int64)
```

Gwelwn fod does gan y person yma diabetes.

Pennod 4

Termau

Llyfryddiaeth

[1] David M. J. Tax; Ferdinand van der Heijden; Robert Duin; Dick de Ridder. Classification, parameter estimation and state estimation: An engineering approach using matlab. 2012.